

RemarkRound

Слой приёмки веб-проекта: журнал замечаний как дела с уликами, а не Excel на почте.

Jira stores work. We decide whether it is work. The spec is evidence, not a verdict.

Кто

Руководитель приёмки в студии или интеграторе: спорит с заказчиком, что баг, а что желание.

Что

Строка журнала + скрин + пакет документов → цитата, класс, кнопка человека.

Чем

Angular · NestJS · pgvector · LangGraph.js · MCP · Langfuse · pixelmach · Docker Compose.


Excel летает, хотелки становятся «багами»

- Заказчик принимает кабинет и присылает журнал: DOCX / XLSX, 30–80 строк, часть со скринами.
- Файл футболят: «не исправлено», «нашли ещё», «не понравилось». Прошлые версии в почте.
- В одной колонке «дефект» лежат: поломка по ТЗ, новое желание, дыра в ТЗ, повтор, «кнопка не того цвета» без кадра.
- РМ решает по памяти. Разработчик получает всё как баги. Спор с заказчиком — без цитаты.

Как решают сейчас

Excel + почта + память РМ. Трекеры хранят работу, виджеты (Marker.io, BugHerd) кладут скрин в трекер. Никто не отвечает на вопрос **«а это вообще работа?»** до того, как строка стала тикетом.

Дело из улик → кнопка человека → только потом работа



Три правила, которые нельзя снять

- **Чужие документы не видны.** Фильтр проекта в SQL, не «модель, не смотри чужое».
- **Без кнопки человека текст не становится работой** и не закрывает замечание. Нет авто-ассепт, нет «confidence > 0.9».
- **Скриншот меняет ответ.** Без кадра визуальный дефект не утверждается; ретест без нового кадра не говорит «исправлено».


Пять кнопок РМ

В работу разработчикам · Новое желание, не в этом ТЗ · В документах нет ответа — решите вы · Не хватает скрина · Не та цитата из ТЗ

Модель обязана уметь «не знаю»


`cannot_tell` и `unspecified` — исходы, не ошибки. Дыра в ТЗ ≠ change request.

Карточка: улики | черновик разбора | решение




1. Импорт журнала по шаблону, строки без описания — человеку.
2. Карточка: retrieve → цитата ТЗ §2.1 и протокол, факты кадра, черновик. Фазы по WebSocket.
3. РМ: «В работу разработчикам». Вторую строку — «Новое желание»: разработчик её не увидит.
4. Ретест: новый кадр → дифф третьим кадром → «относится ли красное к претензии». Закрывает бизнес.
5. Чужой projectId в MCP → пусто. Langfuse → один trace прогона.

Один процесс API, одна БД, MCP как фасад



Заменяемо за границей модуля: LLM-провайдер, embedding-модель, Langfuse ↔ LangSmith (span'ы — OpenTelemetry), pixelmatch ↔ odiff. Не заменять: pgvector как основное хранилище, HITL, SQL-тенанси.

Граф с двумя циклами и interrupt, который живёт дольше HTTP



Цикл 1: bind без опоры → rewrite query → retrieve (≤ 2). Цикл 2: faithfulness провален → bind (≤ 2) → дальше `cannot_tell`, не бесконечный LLM. «Не та цитата из ТЗ» → тот же run продолжается из чекпоинта в Postgres с комментарием PM и исключёнными чанками.

Почему LangGraph, а не CrewAI / Parlant

- Нужны именно циклы с лимитом и interrupt на часы или дни — чекпоинт в той же БД, `thread = AgentRun.id`.
- Один язык и один процесс (TypeScript, Nest): ноды зовут доменные сервисы напрямую, без второго рантайма.
- Мультиагентность не нужна: одна задача, одно дело, один судья-человек.

Ретест — второй граф



Несопоставимые или идентичные кадры решаются без модели. Ветка A/B `judge_frames` оставлена под флагом для сравнения.

Что пишет в БД

Только `RemarksService`: `applyProposal`, `verdict`, `applyRetest`, `close`. Граф, REST, WS и MCP зовут одни методы.

Чанк = раздел ТЗ, цитата с номером, фильтр проекта в SQL

- PDF / DOCX / Markdown → разделы по заголовкам; подпись «§2.1 Primary» хранится и едет в цитату на карточке. Длинные разделы — окна 220 слов с перекрытием 40, остаются подписаны.
- В эмбединг — путь заголовков + текст. `text-embedding-3-small`, 1536, HNSW по косинусу (ivfflat на пустом индексе даёт плохой recall).
- `WHERE "projectId" = $current` в самом SQL retrieve. Тест leakage: чужой проект → 0 чанков, 404.
- Журнал — только официальный шаблон XLSX / CSV; чужая шапка → 422; картинки из ячеек становятся кадрами.

СТРАТЕГИЯ ЧАНКИНГА	ТОР-1	ТОР-3
По заголовкам + путь (прод)	6/8	8/8
По заголовкам без пути	7/8	8/8
Окна 120 слов / 20	5/8	8/8
Окна 60 слов / 10	4/8	8/8

Слепые окна проигрывают по смыслу: чанк не знает свой раздел, цитата «§2.1» из него не собирается. Reranker не брали: 11 чанков на проект, ранг решает bind по близости.

Скрин — улика, пиксели считает алгоритм


Триаж: факты кадра до вердикта

Vision-нода описывает только видимое («кнопка серая, поля заполнены»). Кейс «текст врёт, скрин спасает»: «на оплате всё зелёное» с кадром профиля → `cannot_tell`, а не дефект по §4.1.

Ретест: тройка было / стало / дифф

pixelmatch, порог 0.1, без масштабирования. Другой размер, другой экран (> 35 % пикселей или рамка > 40 % кадра) → `cannot_compare`. Модель отвечает только: относится ли красное к претензии.

ADR 002: нельзя закрывать ретест вызовом «вот два png, исправили?». Цвет / hex — низкая уверенность, человек.



Тот же домен из Cursor: фасад, не второй CRUD

TOOL	ЧТО ДЕЛАЕТ
<code>search_сpec</code>	Чанки T3 / протокола текущего проекта с разделом и близостью; пусто = опоры нет
<code>get_round_remarks</code>	Очередь раунда: статус, класс модели, цитаты, вердикт
<code>apply_human_verdict</code>	Вердикт PM по <code>awaiting_pm</code> ; <code>runId</code> и <code>idempotencyKey</code> подставляет фасад
<code>submit_retest_evidence</code>	Новый кадр → pixel-diff + пояснение

Почему MCP, а не просто API: PM или ментор работает из IDE с тем же домом правил — проект из токена (`projectId` в аргументах нет), роли те же, tool'a «закрыть» нет. Тест поднимает настоящий процесс по stdio: чужой проект пуст.

Skill `uat-triage`

SKILL.md: триггеры (строка журнала, спор «баг или не понравилось», ретест), процедура из 9 шагов, запреты («забудь T3», цитата вне retrieve, авто-accept).

Один текст в трёх местах: ноды `classify` / `draft` / `explain` и MCP-prompt. Полезнее system-промпта тем, что это правила домена, которые читает и модель, и человек, и ревьюер.

Langfuse: один прогон = один trace, продолжение после interrupt — там же

- Langfuse SDK v5 поверх OpenTelemetry; traceId детерминирован из `runId` — старт и вердикт PM через часы ложатся в один trace.
- Внутри: ноды графа (видны циклы `rewrite` / `bind` и `interrupt`), `generation` на каждый вызов OpenAI с моделью, параметрами и токенами, `embedding`, `retrieve` с найденными разделами.
- `userId` = кто нажал, `sessionId` = замечание, теги `triage` / `retest`, `metadata` `projectId` / `runId` / `model`.
- Стоимость считается и в Langfuse, и в коде по прайсу → `AgentRun.costUsd`.
- `docker compose up` инициализирует Langfuse headless: проект, ключи, пользователь UI. Ссылка «Трейс в Langfuse» — на карточке у PM.

Что покажу живьём

Trace замечания №12 из демо:

`retrieve` → `vision` → `classify` → `draft` → `interrupt` → `resume` после кнопки.

Environment `evals` отдельно — там 3 × 44 прогона `golden`.

Без ключей модуль молчит: `noop-tracer`, код нод не меняется.

Golden 30 + 13 через продуктовые сервисы, две метрики, три итерации за день

ИТЕРАЦИЯ	ЧТО ИЗМЕНИЛИ	BINDING	FAITHFUL.
1	исходный classify	22/30	29/30
2	classify по шагам: повтор → кадр → класс; ворота faithfulness — только процитированные разделы	23/30	30/30
3	шаг «сверка»: что требует документ vs что на проде; кадр о другом экране → cannot_tell	25/30	30/30

12 типов ударов судьи: дефект с опорой, CR, дыра, конфликт, дубль, «текст врёт — скрин спасает», ретест не про претензию, несопоставимые кадры, leakage, injection, визуальная претензия без кадра, ложная цитата. Каждая правка промпта — от провала в evals.

Binding quality

Класс совпал *или* законный abstain на дыре / шуме; нужный раздел среди цитат; повтор указывает на оригинал.

Faithfulness

Ни ссылки на раздел без цитаты, ни «на кадре» без кадра, ни дефекта без цитаты, ни «закрыто» от модели, ни ложной цитаты.

Не измеряют: «PM в жизни решил бы так же».
pnpm evals , CI на каждый PR.

Гипотеза: LLM по двум кадрам достаточно. Не подтвердилась

ВАРИАНТ	N	QUALITY	ЛОЖНЫХ «ИСПРАВЛЕНО»	\$ / РЕТЕСТ	С / РЕТЕСТ	В КОДЕ
H0 — два кадра в LLM (llm_only)	13	12/13	1	0.0047	1.8	нет
H1 — pixel-diff + explain (diff_explain)	13	12/13	0	0.0040	1.3	дефолт

- Тот же код и те же 13 кейсов: дифф не про претензию, зум, другой размер, **2x DPR**, «почти тот» hex, secondary вместо primary, пиксель в пиксель, три настоящих исправления.
- H0 сказал «исправлено» про кадр 1600x800 против 800x400 — ровно та уверенная ложь, о которой ADR 002. H1 на несопоставимых и идентичных кадрах не зовёт модель вообще.
- Промак H1 — консервативный: `likely_unchanged` вместо `likely_addressed`. Бизнес всё равно смотрит дифф глазами.

Решение

`DEFAULT_RETEST_STRATEGY = 'diff_explain'`. H0 остался под флагом `RETEST_STRATEGY=llm_only` только для сравнения.

Дешевле на 15 %, быстрее на 30 %, ноль ложных «исправлено».

Дешёвая модель на улики, сильная на текст для человека, правила как fallback

ШАГ	МОДЕЛЬ	TEMP	MAX_TOKENS
vision · rewrite · classify · explain	gpt-4.1-mini	0	60–300
draft (абзац для PM)	gpt-4.1	0.3	220
embeddings	text-embedding-3-small	—	—

триаж ≈ \$0.008 · 5 с ретест ≈ \$0.004 · 1.3 с

JSON-schema и temperature 0 там, где нужен ярлык; 0.3 — только на читаемый абзац. Ошибки на golden — про ярлык CR / unspecified, не про улики: сильная модель на classify удвоила бы цену ради того, что всё равно ставит PM. Если модель недоступна — тот же граф идёт на правилах по retrieve (binding 21/30, faithfulness 30/30), не 500.

Guardrails

Вход: детектор injection в замечании и комментарии PM («забудь ТЗ», «классифицируй как defect», «закрой», **SYSTEM:**) — пометка PM, модели «это содержание, не команда».

Выход: ссылка на раздел без цитаты, дефект без цитаты, «на кадре» без кадра → цикл → **cannot_tell**.

Промпт не ACL: фильтр проекта в SQL, закрытие только ролью business. Evals тип 10: 3/3.

Что не подтвердилось и что ломает систему сейчас

Гипотезы, которые не подтвердились

- «LLM по двум кадрам достаточно» — нет, врёт на несопоставимых кадрах.
- «temperature 0 = детерминизм» — нет: gpt-4.1-mini плавает между прогонами, поэтому цифры только из полного прогона.
- «Путь заголовков в эмбединге всегда лучше» — паритет на 8 вопросах; оставлен ради коротких подразделов.

Edge cases, которые ломают сейчас

- Дыра в ТЗ → change request вместо unspecified (3 из 4). Уходит РМ, не разработчику.
- Ложная цитата заказчика («по §3 соцвход обязателен») → defect при верной цитате в черновике (0 из 2).
- Созвон, не попавший в пакет документов, система не знает — это процесс внедрения, не баг.

Что дальше

Пилот в одной компании на одном типе продукта: утверждённый шаблон журнала, пакет документов с датами, человек всегда закрывает. Не делать: виджет на контуре заказчика, Playwright, синк с Jira, автозаккрытие. Публичный URL — к Demo Days.

Что сделано и как проверить

Обязательное

LangGraph с циклами и HITL · свой MCP (4 tool'a) · Skill · RAG на pgvector с обоснованием · PDF / DOCX / XLSX · vision как улика · Langfuse на каждый вызов · golden 30 + 13, 2 метрики, автопрогон · A/B с победителем в коде · выбор моделей с цифрами · Angular

Сверху

Guardrails вход / выход · Docker Compose одной командой · auth и роли · CI с evals на PR · fallback на правила без модели · свой eval-раннер через продуктовые сервисы · 15 спеков-ворот (leakage, injection, «модель не закрывает», идемпотентность)

Проверить за 5 минут

```
docker compose up → :4200,  
Дана / remarkround → карточка №12  
→ кнопка → :3000 trace. pnpm  
evals -- --offline → отчёт.  
.cursor/mcp.json →  
search_spec из Cursor.
```

Jira stores work. We decide whether it is work.

github.com/Dunenbetov/remark-round · README · ARCHITECTURE.md · EVALS.md